

# SY09 Printemps 2022

## TD/TP 10 — Régression logistique

### 1 Partie pratique

La régression logistique est implémentée dans `scikit-learn` à travers la classe `LogisticRegression` et est disponible avec l'instruction suivante

```
from sklearn.linear_model import LogisticRegression
```

Les arguments intéressants lors de l'instanciation de la classe sont les suivants :

- `penalty` : le type de régularisation ajoutée à la fonction objectif à minimiser. Par défaut, une régularisation  $\ell_2$  est utilisée. Pour pouvoir comparer à notre implémentation on utilisera `penalty="none"`. Sinon, il est en effet conseillé d'utiliser la régularisation par défaut.

Après apprentissage, les attributs suivants sont disponibles :

- `coef_` : les coefficients appliqués aux descripteurs,
- `intercept_` : le coefficient constant.

#### 1.1 Régression logistique

[1] Apprendre un modèle de régression logistique sur le jeu de données présent dans le fichier `SynthPara_n1000_p2.csv` du TP sur l'analyse discriminante et visualiser la frontière de décision.

[2] En utilisant les attributs `coef_` et `intercept_`, retrouver la frontière de décision.

[3] Utiliser l'argument `levels` pour ajouter les lignes de niveaux des probabilités a posteriori. On pourra par exemple prendre 0.1, 0.5 et 0.9.

#### 1.2 Régression logistique quadratique

Il est possible de généraliser le modèle de régression logistique de manière très simple. La stratégie consiste à transformer les données dans un espace plus complexe, dans lequel les classes peuvent être séparées par un hyperplan. La régression logistique est alors effectuée dans cet espace.

Le modèle ainsi défini est donc plus flexible (il permet de construire une frontière de décision plus complexe) ; mais il peut également s'avérer moins robuste que le modèle classique déterminé dans l'espace des caractéristiques initiales, puisqu'il nécessite d'estimer davantage de paramètres.

Par exemple, dans le cas où les individus sont décrits par les variables naturelles  $X^1$ ,  $X^2$  et  $X^3$ , la régression logistique quadratique consiste à apprendre un modèle de régression logistique classique dans l'espace  $\mathcal{X}^2 = \{X^1, X^2, X^3, X^1X^2, X^1X^3, X^2X^3, (X^1)^2, (X^2)^2, (X^3)^2\}$ , plutôt que dans l'espace  $\mathcal{X} = \{X^1, X^2, X^3\}$  constitué des trois variables naturelles.

`Scikit-learn` permet de réaliser tout type de transformations de données qui peuvent être interprétées comme un modèle qu'on apprend avant de soumettre les données en entrée et récupérer la sortie. La classe `PCA` est un exemple d'un tel modèle. L'appel de la méthode `fit_transform` permet d'apprendre le modèle et de renvoyer les données transformées.

Les transformations polynomiales (et donc quadratiques) sont déjà implémentées dans `scikit-learn` grâce au modèle `PolynomialFeatures` disponible grâce à l'instruction suivante

```
from sklearn.preprocessing import PolynomialFeatures
```

Cette classe prend en argument le degré de l'expansion polynomiale à réaliser. Par exemple, le modèle suivant

```
poly = PolynomialFeatures(degree=3)
```

réalise l'expansion polynomiale de degré 3 lors de l'appel à `fit_transform`.

```
In [1]: X = np.array([[1], [2], [3]])
        from sklearn.preprocessing import PolynomialFeatures
        poly = PolynomialFeatures(degree=3)
        poly.fit_transform(X)

Out [1]: array([[ 1.,  1.,  1.,  1.],
                [ 1.,  2.,  4.,  8.],
                [ 1.,  3.,  9., 27.]])
```

4 Réaliser l'expansion polynomiale de degré 2 du jeu de données et apprendre une régression logistique sur le nouveau jeu de données.

Afin de grouper ces deux opérations successives au sein d'un même modèle qui réalisera la transformation ainsi que l'apprentissage de la régression logistique lors d'un seul appel à une méthode `fit`, on va utiliser un *pipeline*. On peut créer un *pipeline* en utilisant la fonction `make_pipeline` et en spécifiant la liste des modèles à appliquer successivement.

```
from sklearn.pipeline import make_pipeline
pipe = make_pipeline(cls1, cls2, cls3)
pipe.fit(X, y)
```

On peut alors utiliser le méthode `predict` sur le *pipeline* `pipe` de façon transparente sans avoir à nous soucier des transformations intermédiaires.

5 Créer un *pipeline* réalisant l'expansion polynomiale suivie de la régression logistique et visualiser dans le plan l'algorithme de discrimination résultant avec la fonction `add_decision_boundary`.

6 Quelle est la forme des frontières de décision ?

### 1.3 Implémentation de la régression logistique binaire

Dans cette section, on se propose d'implémenter une régression logistique binaire. On va utiliser la méthode de Newton-Raphson décrite en détails dans le polycopié de cours.

On pourra comparer avec les coefficients obtenus pour l'implémentation de `scikit-learn` avec les instructions suivantes.

```
from sklearn.linear_model import LogisticRegression as
↪ SklearnLogisticRegression
sk_cls = SklearnLogisticRegression(penalty="none")
sk_cls.fit(X, y)
sk_cls.coef_
sk_cls.intercept_
```

7 Compléter le fichier `src/logistic_regression.py`.

## 1.4 Régression logistique sur données transformées

Dans cette section, nous allons appliquer une régression logistique sur des données qui vont être d'abord transformées de la manière suivante :

1. on se donne  $k$  points parmi le jeu de données qu'on appelle des centres,
2. pour chaque centre, on génère les distances de chaque exemple du jeu de données à ce centre,
3. on rassemble ces  $k$  caractéristiques dans un nouveau jeu de données.

**8** En utilisant le jeu de données présent dans le fichier `Synth1-2000.csv` du TP07, déterminer  $k$  centres à l'aide de l'algorithme des *k-means*.

**9** Former un nouveau jeu de données en calculant toutes les inter-distances entre le jeu de données d'origine et les centres calculés par la méthode des *k-means*.

On pourra utiliser la fonction `pairwise_distances`.

**10** À l'aide du transformeur `FunctionTransformer`, créer un modèle `scikit-learn` qui réalise la transformation de la question précédente.

On pourra s'inspirer du code suivant

```
from sklearn.preprocessing import FunctionTransformer
from sklearn.metrics import pairwise_distances

def distances_to_centers(centers, metric="euclidean"):
    def distances_to_centers0(X):
        # Calcul des inter-distances entre `X` et `centers`
        return ...
    return distances_to_centers0

# Fonction qui prend en argument un jeu de données et le transforme.
func = distances_to_centers(centers)

# Création d'un modèle Scikit-learn qui réalise la transformation
# voulue.
transformer = FunctionTransformer(func)
```

**11** Créer un *pipeline* `scikit-learn` pour définir un modèle qui réalise d'abord la transformation précédente et applique ensuite une régression logistique.

**12** Qu'aurait-on obtenu comme frontière de décision si au lieu de prendre la distance euclidienne on avait pris le carré de cette dernière ?

La méthode précédente présente l'inconvénient d'avoir à effectuer un algorithme des *k-means* avant de construire le *pipeline*. Il est donc impossible d'utiliser `scikit-learn` pour rechercher automatiquement l'hyperparamètre fixant le nombre de centres.

Afin d'inclure cet apprentissage dans l'apprentissage du *pipeline*, nous allons définir un *transformer* `scikit-learn` en héritant des classes `BaseEstimator` et `TransformerMixin`.

**13** Compléter le fichier `src/custom_transformer.py` qui définit un transformeur qui apprend lui-même les centres.

**14** Créer un *pipeline* qui réalise la transformation proposée en calculant lui-même les centres suivie d'une régression logistique.

On peut maintenant utiliser `scikit-learn` pour rechercher le nombre optimal de centres par validation croisée en utilisant la fonction `GridSearchCV`.

Afin d'identifier les hyperparamètres de chaque modèle faisant partie du *pipeline*, il faut tout d'abord nommer chacun de ces modèles en utilisant la classe `Pipeline` au lieu de la fonction `make_pipeline` :

```
from sklearn.pipeline import Pipeline

pipe = Pipeline(
    (
        ("transformer1", Transformer1()),
        ("transformer2", Transformer2()),
        ("classifier", Classifier()),
    )
)
```

Les hyperparamètres de chaque modèle sont alors disponibles dans le *pipeline* sous le nom suivant

`<nom du modèle>__<nom de l'hyperparamètre du modèle>`

avec un double trait souligné séparant le nom du modèle donné dans la définition du *pipeline* et le nom d'un hyperparamètre de ce modèle.



**15** Définir un *pipeline* nommé ainsi qu'une grille de recherche sur le nombre de centres et déterminer le nombre de centres optimal par validation croisée.

Afin de déterminer le meilleur modèle, on utilisera la procédure suivante :

1. déterminer le meilleur modèle en considérant la moyenne des taux de bonne classification sur les ensembles de validation et calculer un intervalle de confiance à 68% sur ce taux,
2. sélectionner le modèle le plus simple dont la moyenne des taux de bonne classification est contenue dans cet intervalle de confiance.

## 2 Analyse des coefficients de la régression

Dans cette partie, on s'intéresse à l'analyse d'un modèle de régression logistique appris sur un jeu de données réelles. Les données décrivent un ensemble de patients de sexe masculin, âgés de 15 à 64 ans, la variable à expliquer étant la présence ou l'absence d'infarctus du myocarde lors de la période d'étude. Les données contiennent 160 cas d'infarctus, contre 302 contrôles.

Pour simplifier la réalisation des questions suivantes, on inclura « manuellement » le terme d'ordonnée à l'origine dans le vecteur de coefficients. On pourra donc charger les données et les pré-traiter au moyen du code suivant :

```
In [2]: Xy = pd.read_csv("data/SAheart.csv")
        X = Xy.iloc[:, 1:-1]
        y = Xy.iloc[:, -1]
        X = X.replace({"famhist": {"Present": 1, "Absent": 0}})
        X = X.drop(["adiposity", "typea"], axis=1)
        X["intercept"] = 1.0
```

**16** Apprendre un modèle de régression logistique sur la totalité des données. On pourra maximiser la vraisemblance avec l'algorithme de Newton-Raphson. On ne fera pas de mise à l'échelle du paramètre d'ordonnée à l'origine.

**17** Implémenter une procédure qui réalise le test de Wald sur les coefficients du modèle de régression appris. Quelles variables sont jugées non significatives ? Pourquoi ?



**18** Implémenter le test du rapport de vraisemblance pour sélectionner un sous-ensemble de variables descriptives significatives. On procédera en enlevant les variables une par une.

**18 a** Implémenter une fonction qui calcule la vraisemblance d'un modèle de régression logistique. On pourra s'appuyer sur la fonction `log_loss` à charger dans le module `sklearn.metrics`.

**18 b** Implémenter une procédure qui supprime une à une les variables les moins significatives du jeu de données tant que les performances du modèle restreint ne sont pas significativement dégradées. Quel est le modèle obtenu ?